

Thiết kế ngược vật liệu meta auxetic bằng mô hình sinh sâu: cân bằng yêu cầu đa mục tiêu và khả năng tổng quát hóa ngoài phân phối

Trịnh Bình Minh*

Bản thảo, 30/09/2026

Tóm tắt

Các mô hình sinh sâu có thể đề xuất ô cơ sở vật liệu meta cho một tính chất hiệu dụng mục tiêu chỉ trong vài mili giây. Tuy nhiên, một thiết kế dùng được phải đồng thời đạt ba yêu cầu. Nó phải khớp mục tiêu sau khi nhị phân hóa và kiểm chứng bằng phần tử hữu hạn (FE). Nó phải chế tạo được. Và lý tưởng là mô hình phải tạo được thiết kế cho cả những mục tiêu nằm ngoài dữ liệu huấn luyện. Chúng tôi nghiên cứu ba yêu cầu này cho ô cơ sở auxetic hai chiều được sinh bởi một bộ mã hóa tự động biến phân có điều kiện (cVAE), tinh chỉnh bằng đồng nhất hóa khả vi. Về độ chính xác, chúng tôi chỉ ra rằng tinh chỉnh không gian ẩn lúc suy luận phải tối ưu chính thiết kế được kiểm chứng. Tinh chỉnh trên đầu ra liên tục của bộ giải mã đưa hàm mục tiêu về $\sim 10^{-10}$, trong khi sai số kiểm chứng vẫn lớn hơn sáu bậc. Ngược lại, khi đưa các phép biến đổi của khâu kiểm chứng vào hàm mục tiêu, R^2 kiểm chứng FE của ν_{12} trên 100 mục tiêu kiểm tra tăng từ 0,874 lên 0,998 (một mẫu) và từ 0,986 lên 0,997 (tốt nhất trong 30 mẫu). Về chọn lọc đa mục tiêu, điểm tổng hợp có trọng số giữa độ chính xác, khả năng chế tạo và thẩm mỹ tương quan ở mức vừa phải với một phép xếp hạng Pareto độc lập (trung vị Spearman 0,71). Với mục tiêu ngoài phân phối, cVAE sinh được thiết kế có dấu hệ số Poisson đúng nhưng chưa từng xuất hiện trong dữ liệu, điều mà truy xuất láng giềng gần nhất không làm được. Tuy vậy, mô hình không ngoại suy được biên độ ra ngoài dải huấn luyện.


Từ khóa: Vật liệu meta auxetic; Mô hình sinh sâu; Vật lý khả vi; Thiết kế ngược; Tối ưu hóa tô-pô; Đồng nhất hóa

1 Mở đầu

Vật liệu meta auxetic co lại theo phương ngang khi bị nén một trục. Hệ số Poisson âm của chúng bắt nguồn từ vi kiến trúc chứ không từ thành phần hóa học của vật liệu cấu thành [1–3]. Đồng nhất hóa ngược bằng tối ưu hóa tô-pô là con đường kinh điển để đi từ một tensor hiệu dụng cho trước đến ô cơ sở [4–6], nhưng mỗi mục tiêu mới đòi hỏi một bài toán tối ưu lặp với hàng trăm lần giải FE. Thiết kế ngược dựa trên dữ liệu phân bố chi phí này ra trước: bộ mã hóa tự động biến phân, mạng đối sinh và mô hình khuếch tán, khi đã huấn luyện trên thư viện mô phỏng, trả về kiến trúc ứng viên gần như tức thì [7–14].

Khi dùng thực tế, một mô hình sinh như vậy phải đáp ứng ba yêu cầu, nhưng chúng hiếm khi được xem xét cùng nhau. (i) *Độ chính xác đã kiểm chứng*. Thứ được chế tạo là phiên bản đã nhị phân hóa và lấy mẫu lại của trường mật độ sinh ra, nên độ chính xác phải được đánh giá bằng phân tích FE trên chính thiết kế đó, không phải bằng mô hình thay thế (surrogate) học được. Surrogate của ánh xạ thuận đã được biết là có thể bị bộ tối ưu và mô hình sinh khai thác [15]. Một mẫu đơn lẻ cũng hiếm khi đạt dung sai chặt, nên các quy trình phải sinh nhiều ứng viên rồi chọn bằng FE [13]. (ii) *Đa mục tiêu*. Một thiết kế khớp mục tiêu nhưng có đảo vật liệu rời rạc, thanh mảnh dưới độ phân giải chế tạo, hoặc biên không ghép lát được thì không dùng được. Do đó độ chính xác phải được cân bằng với khả năng chế tạo, và ở mức ưu tiên thấp hơn, với tính đều đặn hình học. (iii) *Mục tiêu ngoài phân phối (OOD)*. Lý do chính để dùng mô hình sinh thay

*[Đơn vị công tác và thông tin tác giả liên hệ - sẽ bổ sung.]



Hình 1: Quy trình thiết kế ngược. Mọi ứng viên đều được kiểm chứng bằng đồng nhất hóa FE sau đúng các bước hậu xử lý mà một thiết kế đem chế tạo sẽ trải qua. Bước chọn kết hợp độ chính xác đã kiểm chứng với khả năng chế tạo (liên thông, kích thước chi tiết tối thiểu, tuần hoàn) và điểm thẩm mỹ trọng số thấp. Chi tiết bước tinh chỉnh ở Hình 2.

vì tra cứu trong thư viện huấn luyện là nó có thể tạo thiết kế cho những mục tiêu mà thư viện không chứa. Việc nó có làm được hay không, và theo hướng nào trong không gian tính chất, là câu hỏi thực nghiệm.

Bài báo này giải quyết ba yêu cầu trên bằng một quy trình và một giao thức đánh giá duy nhất. Trong đó mọi con số đều được kiểm chứng FE trên thiết kế đã nhị phân hóa, và mọi phép so sánh đều kèm khoảng tin cậy ghép cặp. Các đóng góp của chúng tôi gồm:


1. **Tinh chỉnh không gian ẩn nhận biết nhị phân hóa.** Chúng tôi tinh chỉnh vector ẩn của một cVAE cố định bằng gradient giải tích chính xác của bộ giải đồng nhất hóa tuần hoàn. Chúng tôi chỉ ra rằng tinh chỉnh chỉ đáng tin khi hàm mục tiêu được tính trên thiết kế được kiểm chứng, tức sau khi ép biên tuần hoàn, chiếu Heaviside với tham số tăng dần [16, 17] và lấy mẫu lại láng giềng gần nhất. Chúng tôi cũng đưa ra bằng chứng trực tiếp về hiện tượng khai thác vật liệu xám xảy ra nếu không làm vậy.
2. **Chọn lọc đa mục tiêu có kiểm tra độc lập.** Chúng tôi xếp hạng ứng viên bằng điểm tổng hợp có trọng số giữa độ chính xác, khả năng chế tạo và thẩm mỹ, rồi kiểm tra điểm này với một phép xếp hạng Pareto độc lập thay vì mặc định nó hợp lý.
3. **Đặc trưng hóa OOD có cơ sở vật lý.** Chúng tôi chỉ ra rằng các mục tiêu đối xứng $\nu_{12} = \nu_{21} \leq -1$ không chấp nhận được với ô cơ sở trực hướng, khiến các bộ đánh giá “cực trị” ngây thơ trở nên vô hiệu. Sau đó chúng tôi tách khả năng tổng quát hóa theo *dấu* của hệ số Poisson, nơi cVAE thành công còn truy xuất thất bại, khỏi khả năng tổng quát hóa theo *biên độ*, nơi mọi phương pháp đều bão hòa ở biên dữ liệu huấn luyện.
4. **Kết quả âm tính có kiểm soát.** Cả đầu hồi quy Kolmogorov–Arnold (KAN) lẫn bộ giải mã biểu diễn ẩn wavelet (WIRE) đều không cải thiện so với baseline tích chập khi đo bằng chỉ số kiểm chứng FE.

2 Kết quả

2.1 Khung phương pháp và giao thức đánh giá

Hình 1 trình bày quy trình. cVAE ánh xạ cặp mục tiêu (ν_{12}^*, ν_{21}^*) cùng vector ẩn $z \sim \mathcal{N}(0, I)$ thành ảnh mật độ 64×64 . cVAE được huấn luyện hai giai đoạn; giai đoạn hai dùng loss tính bằng đồng nhất hóa FE trên các mẫu tiên nghiệm (mục Phương pháp). Với mỗi mục tiêu, N vector ẩn được giải mã và hậu xử lý. Hậu xử lý gồm ép biên tuần hoàn, lấy ngưỡng 0,5 và lấy mẫu lại láng giềng gần nhất về lưới FE 50×50 . Mỗi ứng viên sau đó được đồng nhất hóa FE và chấm điểm khả năng chế tạo cùng thẩm mỹ. Ứng viên tốt nhất theo điểm tổng hợp có thể được tinh chỉnh tiếp trong không gian ẩn. Thiết kế đã tinh chỉnh chỉ được giữ nếu sai số kiểm chứng của nó thấp hơn (tinh chỉnh “có kiểm soát”).

Mọi số liệu độ chính xác đều được kiểm chứng FE trên thiết kế đã nhị phân hóa. Bộ đánh giá trong phân phối (IN100) gồm 100 điều kiện của tập kiểm tra, rút với seed cố định. Các phép so sánh kèm khoảng tin cậy (KTC) 95% bootstrap ghép cặp theo điều kiện [18]. Tiêu chí thành công được ghi lại trước mỗi thí nghiệm (mục Phương pháp).



Hình 2: Tinh chỉnh không gian ẩn nhận biết nhị phân hóa. Đầu ra của bộ giải mã cố định đi qua các phiên bản khả vi của những phép biến đổi dùng khi kiểm chứng rồi mới vào đồng nhất hóa FE, nên đại lượng được tối ưu chính là đại lượng được kiểm chứng. Biến thể liên tục bỏ khối nét đứt và dùng nội suy song tuyến tính. Khâu kiểm chứng thay H_β bằng ngưỡng cứng 0,5.

2.2 Độ chính xác đã kiểm chứng đòi hỏi tối ưu chính thiết kế được kiểm chứng

Tinh chỉnh liên tục khai thác vật liệu xám. Tinh chỉnh đầu ra liên tục của bộ giải mã (30 bước L-BFGS [19], gradient qua bộ giải mã và qua độ nhạy chính xác của đồng nhất hóa) có ích cho mẫu đơn lẻ của mô hình sản xuất. Trên IN100, $R^2(\nu_{12})$ tăng từ 0,874 lên 0,976 và sai số tuyệt đối trung bình (MAE) của ν_{12} giảm 57,7% (KTC 95%: 49,4–64,6%; Bảng 1, Hình 3b). Tuy nhiên, cùng phép tinh chỉnh đó lại làm xấu đi ứng viên tốt nhất trong 30 mẫu. MAE(ν_{12}) tăng từ 0,0152 lên 0,0246, tức thay đổi –62,5% (KTC –98,3 đến –33,9%), và R^2 giảm từ 0,986 xuống 0,968. Diễn biến hàm mục tiêu giải thích nguyên nhân (Hình 4). Khi kết thúc tinh chỉnh liên tục, trung vị hàm mục tiêu là $2,5 \times 10^{-10}$, nhưng trung vị bình phương sai số kiểm chứng của thiết kế đã nhị phân hóa là $4,4 \times 10^{-4}$. Bộ tối ưu khớp mục tiêu trên một trường có mật độ trung gian không còn tồn tại sau khi lấy ngưỡng. Đây chính là dạng thất bại của việc khai thác surrogate, nhưng xuất hiện ngay bên trong một mô hình vật lý chính xác.

Tinh chỉnh nhận biết nhị phân hóa. Khi đặt các phiên bản khả vi của phép biến đổi kiểm chứng vào trong hàm mục tiêu (Hình 2; 32 bước trên $\beta \in \{1; 4; 16; 64\}$), khoảng cách giữa hàm mục tiêu và kết quả kiểm chứng giảm ba bậc (Hình 4). Mọi tiêu chí trong phân phối đặt trước đều đạt (Bảng 1).

- **Mẫu đơn lẻ.** $R^2(\nu_{12})$ tăng từ 0,874 lên 0,998 và MAE(ν_{12}) giảm 91,8% (KTC 89,0–93,9%). Sai số tương đối trung bình của ν_{12} giảm từ 14,4% xuống 2,6%, và $R^2(\nu_{21})$ tăng từ 0,477 lên 0,883.
- **Sau khi chọn tốt nhất trong 30 mẫu.** MAE(ν_{12}) giảm 62,6% (KTC 50,7–72,1%) và $R^2(\nu_{12})$ tăng từ 0,986 lên 0,997. Tinh chỉnh có kiểm soát chấp nhận 92% số lần tinh chỉnh và giảm MAE(ν_{12}) 69,1% (KTC 61,6–75,4%), không tốn thêm lần giải FE nào.


Sau bước chọn tốt nhất trong 30 mẫu, MAE(ν_{21}) giảm từ 0,0327 xuống 0,0128, trong khi $R^2(\nu_{21})$ giảm từ 0,802 xuống 0,712. Như vậy một số điều kiện có sai lệch ν_{21} lớn hơn, và quy tắc kiểm soát dựa trên tổng sai số không phải lúc nào cũng loại được chúng. Tinh chỉnh tốn trung bình 77 lần giải FE mỗi điều kiện. Với 50–100 ms mỗi lần giải kèm độ nhạy trên lưới 50×50 , chi phí này tương đương vài giây cho mỗi thiết kế.

2.3 Yêu cầu đa mục tiêu: khả năng chế tạo và xếp hạng tổng hợp

Thiết kế chính xác chưa chắc đã chế tạo được. Mỗi ứng viên được kiểm tra (a) tính liên thông, không có thanh mảnh hơn hai pixel, và (b) tính tuần hoàn, tức các cạnh đối diện phải khớp để ô cơ sở ghép lát được bằng phép tịnh tiến (mục Phương pháp). Với một cVAE trước đây chưa ép biên tuần hoàn, chỉ 0–3,5% mẫu sinh ra qua được cả hai kiểm tra. Tỷ lệ này đồng đều trên toàn không gian tính chất, nên vấn đề nằm ở hành vi của bộ giải mã chứ không phải ở độ phủ dữ liệu. Ép tuần hoàn bằng cách lấy trung bình các cạnh đối diện trước khi nhị phân hóa là một phép toán không cần huấn luyện. Nó đã nâng tỉ lệ qua kiểm tra lên hơn một bậc, và được áp dụng trong mọi lần kiểm chứng ở bài báo này. Với phép ép này, 24,7% mẫu của mô hình sản xuất qua được mọi kiểm tra (300 mục tiêu kiểm tra, $N = 30$; Bảng 2). Trong phân phối, phép ép tuần hoàn vì vậy không buộc phải đánh đổi với độ chính xác.

Bảng 1: Độ chính xác kiểm chứng FE trên IN100 (100 mục tiêu kiểm tra, cVAE sản xuất). ΔMAE là mức giảm tương đối $\text{MAE}(\nu_{12})$ so với thiết kế chưa tinh chỉnh cùng chế độ, kèm KTC 95% bootstrap ghép cặp (10 000 lần lấy mẫu lại). Giá trị âm nghĩa là tinh chỉnh làm kết quả xấu đi. Số lần gọi FE tính trên mỗi điều kiện, gồm cả bước chọn.

Chế độ	Tinh chỉnh	$R^2(\nu_{12})$	$\text{MAE}(\nu_{12})$	$R^2(\nu_{21})$	ΔMAE [KTC 95%]	Lần gọi FE
Mẫu đơn lẻ	không	0,874	0,0517	0,477	–	1
	liên tục	0,976	0,0219	0,643	+57,7% [49,4; 64,6]	51
	nhận biết nhị phân hóa	0,998	0,0043	0,883	+ 91,8% [89,0; 93,9]	78
Tốt nhất / 30	không	0,986	0,0152	0,802	–	30
	liên tục	0,968	0,0246	0,637	–62,5% [–98,3; –33,9]	79
	nhận biết nhị phân hóa	0,997	0,0057	0,712	+62,6% [50,7; 72,1]	107
	có kiểm soát	0,998	0,0047	–	+ 69,1% [61,6; 75,4]	107




Hình 3: ν_{12} kiểm chứng FE so với mục tiêu trên IN100 ($n = 100$, mẫu đơn lẻ của cVAE sản xuất): (a) chưa tinh chỉnh; (b) sau tinh chỉnh liên tục; (c) sau tinh chỉnh nhận biết nhị phân hóa. Ở cả ba ô, mỗi điều kiện xuất phát từ cùng một vector ẩn. Nét đứt: đường đồng nhất.

Trong số các ứng viên của một mục tiêu, bước chọn cực đại hóa điểm tổng hợp $0,6 s_{\text{acc}} + 0,3 s_{\text{man}} + 0,1 s_{\text{aes}}$. Các trọng số mã hóa thứ tự ưu tiên chính xác > chế tạo > thẩm mỹ; đây là lựa chọn thiết kế, không phải đại lượng học được. Để kiểm tra phép vô hướng hóa này có tôn trọng cấu trúc đa mục tiêu hay không, chúng tôi tính tương quan Spearman giữa điểm tổng hợp và tăng sắp xếp không trội (non-dominated sorting) trên ba mục tiêu gốc. Phép tính được làm cho 24 mục tiêu, mỗi mục tiêu 30 ứng viên (Hình 5). Cả 24 hệ số tương quan đều dương (khoảng 0,43–0,89). Trung vị là 0,714, nhưng trung bình 0,693 thấp hơn một chút so với ngưỡng 0,7 đặt trước. Như vậy điểm tổng hợp phù hợp ở mức vừa phải, chưa phải mạnh, với cấu trúc Pareto. Việc ứng viên được chọn luôn nằm trên mặt Pareto thứ nhất là hệ quả toán học tất yếu với trọng số dương, nên không được tính là bằng chứng.

2.4 Tổng quát hóa ngoài phân phối

Mục tiêu chấp nhận được. Trước khi thử ngoại suy, chúng tôi xác định mục tiêu nào thực sự tồn tại. Với vật liệu trực hướng hai chiều, điều kiện xác định dương của ma trận độ mềm đòi hỏi $\nu_{12}\nu_{21} < 1$ [20]. Do đó mục tiêu đối xứng $\nu_{12}^* = \nu_{21}^* \leq -1$ là không khả thi. Trong dữ liệu huấn luyện, giá trị âm nhất $\nu_{12} = -1,95$ đi kèm $\nu_{21} = -0,04$, và tích $\nu_{12}\nu_{21}$ lớn nhất là 0,43. Điều này quan trọng cho việc đánh giá. Một thí nghiệm “auxetic cực trị” trước đây trong dự án đã dùng các mục tiêu như $(-2,1; -2,1)$ và $(-2,2; -1,6)$, và cả sáu mục tiêu đều vi phạm giới hạn này. Thất bại ở đó vì vậy không nói lên điều gì về khả năng ngoại suy, và chúng tôi loại nó khỏi bài này. Các mục tiêu biên độ ngoài dải dưới đây là dị hướng, với $\nu_{21}^* = -0,05$.




Hình 4: Khoảng cách giữa hàm mục tiêu và kết quả kiểm chứng. Mỗi điểm là một điều kiện của IN100. Trục ngang là giá trị cuối của hàm mục tiêu tinh chỉnh; trục dọc là bình phương sai số hệ số Poisson của thiết kế đã nhĩ phân hóa, đo bằng một lần giải FE độc lập. Tinh chỉnh liên tục (hình tròn) đạt hàm mục tiêu gần 10^{-10} trong khi sai số kiểm chứng vẫn ở mức 10^{-4} – 10^{-2} . Tinh chỉnh nhận biết nhĩ phân hóa (hình vuông) kéo các điểm về gần đường đồng nhất. Giá trị dưới 10^{-14} được cắt để hiển thị.

Bảng 2: Các chỉ báo đa mục tiêu. Khối trên: quy trình sản xuất có ép tuần hoàn và chọn tốt nhất trong 30 mẫu, trên 300 mục tiêu kiểm tra. Tỷ lệ chế tạo được: tỷ lệ mẫu sinh ra qua cả ba kiểm tra liên thông, kích thước tối thiểu và tuần hoàn. Tỷ lệ trúng: tỷ lệ mục tiêu có mẫu đầu tiên là auxetic ($\nu_{12} < 0$). Khối dưới: mức phù hợp giữa điểm tổng hợp và tầng Pareto (24 mục tiêu $\times$ 30 ứng viên).

Mô hình	$R^2(\nu_{12})$, tốt nhất/30	Tỷ lệ trúng mẫu đơn	Tỷ lệ chế tạo được
cVAE sản xuất (bộ dữ liệu v2)	0,995	0,997	0,247
cVAE trước đó (bộ dữ liệu v1)	0,998	0,983	0,280
Điểm tổng hợp so với tầng Pareto: Spearman trung bình 0,693, trung vị 0,714, khoảng 0,43–0,89; 24/24 mục tiêu dương.			

Theo dấu: cVAE tổng quát hóa được, truy xuất thì không. Mọi mẫu huấn luyện đều auxetic ($-1,95 \leq \nu_{12} \leq -0,002$). Với sáu mục tiêu không auxetic $0,1 \leq \nu_{12}^* \leq 0,8$, truy xuất lảng giềng gần nhất từ thư viện 57 216 mẫu tất yếu trả về mẫu gần 0 nhất ($\nu_{12} = -0,002$), sai dấu ở mọi mục tiêu. cVAE (tốt nhất trong 10 mẫu) cho ν_{12} dương ở cả sáu mục tiêu (Bảng 3, Hình 6), với MAE 0,19 so với 0,40 của truy xuất. Tuy nhiên, biên độ đạt được bão hòa quanh 0,3: với $\nu_{12}^* = 0,8$, cVAE chỉ đạt 0,30. Như vậy cVAE ngoại suy được *hướng* của tính chất nhưng không đạt đủ biên độ. Thí nghiệm này dùng một checkpoint trước đó (bộ dữ liệu v1) và sáu mục tiêu, nên chỉ nên xem là bằng chứng định tính.

Theo biên độ: mọi phương pháp bão hòa ở biên huấn luyện. Chúng tôi quét $\nu_{12}^* \in \{-1,0; -1,5; -1,75; -2,0; -2,25; -2,5\}$ ($\nu_{21}^* = -0,05$), với 10 lần rút vector ẩn độc lập mỗi mục tiêu, chọn tốt nhất trong 30 mẫu và ép tuần hoàn (Bảng 4, Hình 7). Trong dải huấn luyện, tinh chỉnh nhận biết nhĩ phân hóa đưa trung vị sai số tương đối của ν_{12} về 0,2–0,4%. Vượt quá biên dưới $-1,95$ của dữ liệu huấn luyện, mọi biến thể đều bão hòa. ν_{12} kiểm chứng âm nhất trong toàn bộ 30 thiết kế tại $\nu_{12}^* = -2,5$ là $-1,99$. Khi đó tinh chỉnh không kiểm soát còn kém hơn không tinh chỉnh (32,4% so với 22,5% tại $-2,5$). Biến thể có kiểm soát đạt ngưỡng 8% đặt trước tại $-2,0$ (4,9%), nhưng chỉ vì mục tiêu này nằm cách biên 0,05. Từ



Hình 5: Phân bố trên 24 mục tiêu của tương quan Spearman giữa điểm tổng hợp và tăng Pareto của 30 ứng viên (các mục tiêu: $|\Delta\nu_{12}|$ kiểm chứng, điểm chế tạo, điểm thẩm mỹ). Đường chấm: ngưỡng đặt trước cho giá trị trung bình.

Bảng 3: Mục tiêu OOD đối đầu (dữ liệu huấn luyện chỉ có $\nu_{12} < 0$). ν_{12} kiểm chứng FE của truy xuất láng giềng gần nhất và của cVAE (mẫu đầu tiên và tốt nhất trong 10). Cột cuối: tỉ lệ chế tạo được trong 10 mẫu cVAE.


$(\nu_{12}^*; \nu_{21}^*)$	Truy xuất	cVAE, mẫu đầu	cVAE, tốt nhất/10	Chế tạo
(0,1; 0,1)	-0,002	0,082	0,104	0,6
(0,3; 0,3)	-0,002	0,183	0,204	0,6
(0,5; 0,5)	-0,002	0,191	0,280	0,8
(0,8; 0,8)	-0,002	0,241	0,301	0,6
(0,2; 0,5)	-0,002	0,225	0,194	0,9
(0,5; 0,2)	-0,002	0,109	0,177	0,6
MAE(ν_{12})	0,402	0,237	0,191	

-2,25 trở đi, nó chỉ ngang bằng bước chọn tốt nhất trong 30 mẫu. Tình hình là tìm kiếm cục bộ trong không gian ẩn của bộ giải mã, nên không thể tạo ra biên độ mà bộ giải mã chưa từng học để biểu diễn.

2.5 Thí nghiệm loại bỏ về kiến trúc

Đầu KAN so với đầu tuyến tính. Chúng tôi thay ba lớp tuyến tính của cVAE (trung bình ẩn, log-phương sai và nút cổ chai của bộ giải mã) bằng các lớp Kolmogorov–Arnold [21]. Cả hai loại đầu được huấn luyện với cùng công thức, siêu tham số và seed (123 và 7). KAN chỉ được coi là thắng nếu KTC ghép cặp không chứa 0 ở cả hai seed. Kết quả là KAN không thắng ở chế độ nào (Bảng 5). Ở chế độ sản xuất (tốt nhất trong 30 mẫu, không tinh chỉnh), đầu tuyến tính tốt hơn có ý nghĩa ở cả hai seed. Khi có tinh chỉnh, cả hai đều đạt $R^2(\nu_{12}) = 0,997-0,999$. Đầu KAN có số tham số gấp 3,2 lần (4,79 triệu so với 1,49 triệu) và thời gian mỗi epoch gấp khoảng 1,6 lần, nên chúng tôi giữ đầu tuyến tính.

Bộ giải mã biểu diễn ẩn wavelet. Một bộ giải mã WIRE không phụ thuộc độ phân giải [22] được thử lần cuối. Lần thử này kết hợp phép chiếu Heaviside trong loss vật lý, không ép đối xứng và công thức hai giai đoạn. Tiêu chí đặt trước là tỉ lệ trúng mẫu đơn tối thiểu 30% và R^2 FE dương trên 24 mục tiêu kiểm tra. Kết quả đạt tỉ lệ trúng 12,5% và R^2 FE bằng -7,19 sau bước chọn tốt nhất trong 30 mẫu, trong khi bộ giải mã tích chập đạt tỉ lệ trúng khoảng 99,7%. Chỉ 4,6% mẫu của nó chế tạo được. Vì vậy hướng này được dừng lại.



Hình 6: Tổng quát hóa theo dấu với các mục tiêu đối xứng không auxetic. Truy xuất bị giới hạn bởi thư viện huấn luyện ($\nu_{12} \leq -0,002$). cVAE đạt đúng dấu nhưng bão hòa về biên độ. Nét đứt: đường đồng nhất.

Bảng 4: Quét biên độ dị hướng ($\nu_{21}^* = -0,05$; tốt nhất trong 30 mẫu có ép tuần hoàn; 10 lần lặp mỗi mục tiêu). Giá trị: trung vị sai số tương đối của ν_{12} kiểm chứng FE. Dải huấn luyện của ν_{12} kết thúc tại $-1,95$.


ν_{12}^*	-1,0	-1,5	-1,75	-2,0	-2,25	-2,5
Tốt nhất/30, không tinh chỉnh	0,5%	0,9%	4,1%	11,0%	16,1%	22,5%
+ tinh chỉnh liên tục	1,4%	1,3%	3,2%	36,5%	38,9%	43,9%
+ tinh chỉnh nhận biết nhị phân hóa	0,4%	0,2%	0,3%	12,5%	22,3%	32,4%
+ nhận biết nhị phân hóa, có kiểm soát	0,2%	0,2%	0,3%	4,9%	14,8%	21,9%

3 Thảo luận

Độ chính xác. Phát hiện phương pháp luận trung tâm là: khi tinh chỉnh một thiết kế được sinh ra dựa trên vật lý, hàm mục tiêu phải được tính trên đúng đối tượng sẽ được kiểm chứng. Lấy đạo hàm qua bộ giải chính xác loại bỏ được sai số surrogate, nhưng không loại bỏ được sự lệch giữa đầu ra liên tục của bộ giải mã và ô cơ sở đã nhị phân hóa. Hình 4 cho thấy sự lệch này cho phép bộ tối ưu đạt hàm mục tiêu 10^{-10} trên một trường mà bộ kiểm chứng nhìn thấy rất khác. Vấn đề không lộ ra trên đường cong loss, và chỉ bộc lộ khi tinh chỉnh một baseline mạnh. Các thành phần của cách khắc phục là tiêu chuẩn trong tối ưu hóa tô-pô dựa trên mật độ [16, 17]. Điểm mới là áp dụng chúng lên đầu ra của một mô hình sinh cố định trong quá trình tìm kiếm không gian ẩn, cùng với đúng phép lấy mẫu lại và hậu xử lý tuần hoàn dùng khi kiểm chứng. Nguyên tắc này hẳn cũng mở rộng được cho bất kỳ bước hậu xử lý nào nằm trong khâu kiểm chứng.

Đa mục tiêu. Quy trình xử lý ba mục tiêu ở các giai đoạn khác nhau. Tính tuần hoàn được đảm bảo bằng cấu trúc, tính liên thông và kích thước chi tiết đi vào qua điểm tổng hợp, còn độ chính xác được cải thiện sau cùng bằng tinh chỉnh vẫn giữ biên tuần hoàn. Cách sắp xếp này mang tính thực dụng, và bằng chứng của chúng tôi cho nó mới là một phần. Điểm tổng hợp chỉ phù hợp vừa phải với xếp hạng Pareto. Một nguyên nhân có thể là việc chuẩn hóa theo thứ hạng của số hạng độ chính xác trong từng tập ứng viên, nhưng chúng tôi chưa kiểm chứng điều này. Chúng tôi cũng chưa đo tinh chỉnh có làm thay đổi tính liên thông hay kích thước chi tiết hay không. Người thiết kế cần đảm bảo chắc chắn khả năng chế tạo vẫn có thể giới hạn bước chọn vào các ứng viên qua mọi kiểm tra. Trong các thí nghiệm trước, cách này cần tập ứng viên lớn ($N \approx 1500$) và làm giảm độ chính xác.

Tổng quát hóa ngoài phân phối. Kết quả của chúng tôi gợi ý một phát biểu chính xác hơn cho nhận định phổ biến rằng mô hình sinh “tổng quát hóa được”. Theo dấu của hệ số Poisson, cVAE tạo ra thiết kế



Hình 7: Trung vị sai số tương đối của ν_{12} kiểm chứng FE theo mục tiêu ($\nu_{21}^* = -0,05$). Thanh sai số: khoảng tứ phân vị trên 10 lần rút vector ẩn mỗi mục tiêu; các điểm được dịch ngang để dễ đọc. Vùng tô: ngoài dải huấn luyện. Đường chấm: ngưỡng 8% đặt trước tại $\nu_{12}^* = -2,0$.

Bảng 5: Thí nghiệm loại bỏ KAN so với tuyến tính trên IN100 (hai seed). ΔMAE : mức giảm tương đối $\text{MAE}(\nu_{12})$ của KAN so với tuyến tính (dương là KAN tốt hơn), KTC 95% bootstrap ghép cặp. Chữ đậm: KTC không chứa 0.

Chế độ	$R^2(\nu_{12})$ Tuyến tính / KAN		ΔMAE KAN so với tuyến tính	
	seed 123	seed 7	seed 123	seed 7
Mẫu đơn lẻ	0,852 / 0,904	0,815 / 0,911	+13,3% [-0,2; 24,4]	+18,2% [3,8; 30,4]
Mẫu đơn lẻ + tinh chỉnh	0,994 / 0,997	0,998 / 0,999	+33,2% [-15,1; 60,5]	+33,9% [11,7; 52,3]
Tốt nhất/30	0,977 / 0,974	0,982 / 0,980	-25,2% [-56,2; -1,0]	-19,9% [-42,1; -1,7]
Tốt nhất/30 + tinh chỉnh	0,998 / 0,997	0,998 / 0,999	+11,3% [-38,7; 43,6]	+44,1% [24,9; 59,7]

trong vùng có mật độ dữ liệu huấn luyện bằng 0, điều mà phương pháp tra cứu không thể làm được về mặt cấu trúc. Theo biên độ, mô hình sinh, bước tinh chỉnh và bước chọn tốt nhất trong N mẫu đều dừng ở biên dữ liệu huấn luyện. Vì vậy các tuyên bố về OOD nên nêu rõ hướng trong không gian tính chất, và nên kiểm tra trước rằng mục tiêu là chấp nhận được về vật lý. Ngoại suy biên độ nhiều khả năng cần dữ liệu huấn luyện mới gần biên, ví dụ từ tối ưu hóa tô-pô khởi tạo bằng các thiết kế được sinh ra, hơn là lấy mẫu tốt hơn từ mô hình hiện tại.

Giới hạn. (i) Mọi phân tích dùng đồng nhất hóa đàn hồi tuyến tính, biến dạng nhỏ, cho ô cơ sở hai chiều trên lưới 50×50 với hệ số Poisson vật liệu nền 0,3. Biến dạng lớn và kiến trúc ba chiều chưa được xét. (ii) Thiết kế được kiểm chứng bằng số, kể cả với một bản cài đặt FE độc lập, nhưng chưa được kiểm chứng thực nghiệm. (iii) Thí nghiệm đổi dấu dùng sáu mục tiêu và một checkpoint trước đó; phép quét biên độ dùng 10 lần lặp mỗi mục tiêu. (iv) Điểm thẩm mỹ là một heuristic đơn giản (đối xứng gương và độ trơn biên), chưa được đối chiếu với đánh giá của con người. (v) Trong phân phối, truy xuất láng giềng gần nhất rất cạnh tranh về độ chính xác, nên lợi thế của mô hình sinh thể hiện ở đây chỉ giới hạn ở việc đổi dấu ngoài phân phối. (vi) Tinh chỉnh tốn thêm khoảng 77 lần giải FE mỗi mục tiêu. Chi phí này rẻ ở 2D nhưng sẽ đòi hỏi bộ giải adjoint hiệu quả ở 3D.

4 Phương pháp

4.1 Sinh dữ liệu

Ô cơ sở được sinh bằng tối ưu hóa tô-pô SIMP [23–25] với bộ lọc mật độ [26], điều kiện biên tuần hoàn và đồng nhất hóa dựa trên năng lượng [27–29]. Các hàm mục tiêu auxetic được cực tiểu hóa từ bốn tô-pô khởi tạo, dùng tiêu chuẩn tối ưu (OC) hoặc phương pháp tiệm cận di động [30] tùy tô-pô. Các tham số quy trình (tỉ lệ thể tích, hệ số phạt, bán kính lọc, giới hạn bước, kích thước lỗ rỗng, góc xoay mạng) được sàng lọc bằng lấy mẫu siêu lập phương Latin [31]. Sau đó chúng được tinh chỉnh trong một quy trình thiết kế thí nghiệm thích nghi nhiều lô, dùng dãy Sobol’ [32] và siêu lập phương Latin tối ưu. Các mẫu hội tụ dao động, tô-pô suy biến hoặc nằm ngoài dải vật lý bị loại bỏ. Trường mật độ 50×50 được lọc hộp về ảnh 64×64 và gán nhãn (ν_{12}, ν_{21}) đồng nhất hóa. Bộ dữ liệu sản xuất gồm 13 624 ô cơ sở phân biệt, chia 70/15/15 theo họ tô-pô khởi tạo (2 044 mẫu kiểm tra). Ảnh huấn luyện được tăng cường sáu lần bằng phép xoay và đối xứng; phép xoay 90° hoán đổi $\nu_{12} \leftrightarrow \nu_{21}$. Kết quả là 57 216 mẫu huấn luyện.

4.2 Đồng nhất hóa và độ nhạy chính xác

Trường mật độ $\rho \in [0, 1]^{50 \times 50}$ được rời rạc hóa bằng phần tử tứ giác song tuyến tính với nội suy SIMP cải tiến $E(\rho) = E_{\min} + \rho^p(E_0 - E_{\min})$, trong đó $E_{\min} = 10^{-9}E_0$, $p = 3$ và $\nu_0 = 0,3$. Tensor độ cứng đồng nhất hóa $\mathbf{Q}$ nhận được từ ba trường hợp tải tuần hoàn thông qua năng lượng tương hỗ phần tử [29]. Hệ số Poisson lấy từ $\mathbf{S} = \mathbf{Q}^{-1}$: $\nu_{12} = -S_{12}/S_{11}$ và $\nu_{21} = -S_{12}/S_{22}$. Công thức này vẫn đúng với ô cơ sở bị xoay, dị hướng hoàn toàn. Nhờ công thức năng lượng tự liên hợp, độ nhạy $\partial \mathbf{Q} / \partial \rho_e$ có sẵn mà không cần giải thêm. Độ nhạy được lan truyền giải tích qua $\partial \mathbf{S} = -\mathbf{S}(\partial \mathbf{Q})\mathbf{S}$ và quy tắc đạo hàm thương, trong một hàm autograd tùy biến của PyTorch [33]. Gradient của hàm này khớp sai phân hữu hạn với sai số tương đối dưới 10^{-4} . Bộ giải khớp với một bản cài đặt độc lập bằng scikit-fem [34] tới 10^{-9} trên 24 thiết kế.

4.3 cVAE

cVAE [35, 36] được điều kiện hóa theo $c = (\nu_{12}, \nu_{21})$ và có không gian ẩn 32 chiều. Bộ mã hóa gồm bốn khối tích chập–chuẩn hóa batch–ReLU–pooling (32 đến 256 kênh), giữ lại bản đồ không gian 4×4 , tiếp theo là các lớp tuyến tính cho trung bình và log–phương sai. Bộ giải mã đối xứng với bộ mã hóa, dùng tích chập chuyển vị và đầu ra sigmoid. Giai đoạn 1 huấn luyện với loss tái tạo entropy chéo nhị phân, số hạng KL có khởi động tuyến tính [37], và số hạng nhất quán tính chất từ một surrogate tích chập cố định (trọng số $\gamma = 20$; surrogate đạt R^2 kiểm tra 0,974 cho ν_{12} và 0,964 cho ν_{21}). Giai đoạn 2 tiếp tục từ giai đoạn 1 và thêm bình phương sai số giữa c và hệ số Poisson đồng nhất hóa FE của các mẫu *tiền nghiệm* $z \sim \mathcal{N}(0, I)$ đã giải mã (trọng số 20; 8 mẫu mỗi hai epoch). Đây chính là chế độ dùng khi suy luận, và huấn luyện loss này từ đầu thì thất bại. Tối ưu dùng Adam [38]. Checkpoint được chọn theo R^2 kiểm chứng FE trên các điều kiện kiểm định chứ không theo loss kiểm định, vì khởi động KL làm loss kiểm định không đáng tin.

4.4 Kiểm chứng, khả năng chế tạo và điểm tổng hợp

Một ảnh giải mã được kiểm chứng qua bốn bước: (1) ép biên tuần hoàn, thay các cột rồi các hàng biên đối diện bằng trung bình của chúng; (2) lấy ngưỡng 0,5; (3) lấy mẫu lại lằng giềng gần nhất về 50×50 bằng bảng chỉ số của thư viện ảnh dùng khi xây dựng bộ dữ liệu; và (4) đồng nhất hóa FE. Khả năng chế tạo kết hợp ba kiểm tra trên ảnh nhị phân: pha rắn liên thông duy nhất, kích thước chi tiết tối thiểu hai pixel (phép co hình thái), và tính tuần hoàn (tối đa 10% pixel lệch giữa các cạnh đối diện). Điểm có bậc s_{man} là trung bình của ba chỉ báo. Điểm thẩm mỹ s_{aes} lấy trung bình giữa độ đối xứng gương theo hai trục và nghịch đảo tỉ lệ chu vi/diện tích đã chuẩn hóa, tính với biên tuần hoàn. Điểm chính xác s_{acc} là $|\Delta \nu_{12}|$ chuẩn hóa min–max trong tập ứng viên, đổi dấu để giá trị cao hơn là tốt hơn. Phép kiểm tra Pareto áp dụng sắp xếp không trội lặp trên ba mục tiêu gốc, rồi tính tương quan giữa tăng thu được và điểm tổng hợp cho từng mục tiêu.

4.5 Tinh chỉnh không gian ẩn

Cho ν^* và vector ẩn xuất phát z_0 (mẫu đơn lẻ hoặc ứng viên tốt nhất trong N mẫu), chúng tôi cực tiểu hóa

$$\mathcal{L}_\beta(z) = \frac{1}{2} \left\| \nu \left(\mathcal{R} \circ H_\beta \circ \mathcal{P} \circ D(z, c) \right) - \nu^* \right\|_2^2, \quad (1)$$

trong đó D là bộ giải mã cố định, $\mathcal{P}$ là phép ép biên tuần hoàn (tuyến tính), và $\mathcal{R}$ là phép lấy mẫu lại láng giềng gần nhất được cài đặt như một phép gather khả vi với cùng bảng chỉ số. Cuối cùng,

$$H_\beta(\rho) = \frac{\tanh(\beta\eta) + \tanh(\beta(\rho - \eta))}{\tanh(\beta\eta) + \tanh(\beta(1 - \eta))}, \quad \eta = 0,5, \quad (2)$$

là phép chiếu Heaviside làm trơn [17]. 32 bước L-BFGS (bước 0,5, tìm kiếm đường strong-Wolfe) được chia đều cho $\beta \in \{1; 4; 16; 64\}$. L-BFGS được khởi động lại ở mỗi mức, vì thông tin độ cong từ phép chiếu mềm hơn không còn đúng cho mức mới. Baseline liên tục áp loss lên $D(z, c)$ với nội suy song tuyến tính trong 30 bước. Tinh chỉnh có kiểm soát chỉ giữ thiết kế đã tinh chỉnh nếu $|\Delta\nu_{12}| + |\Delta\nu_{21}|$ kiểm chứng của nó nhỏ hơn thiết kế xuất phát.

4.6 Giao thức ngoài phân phối và baseline truy xuất

Phương pháp truy xuất trả về mẫu huấn luyện có khoảng cách Euclid nhỏ nhất tới mục tiêu trong không gian (ν_{12}, ν_{21}) . Thí nghiệm đối đầu dùng sáu mục tiêu không auxetic, 10 mẫu cVAE mỗi mục tiêu và chọn bằng FE. Phép quét biên độ dùng sáu mục tiêu dị hướng với $\nu_{21}^* = -0,05$ và 10 lần lặp độc lập của bước chọn tốt nhất trong 30 mẫu cho mỗi mục tiêu. Tính chấp nhận được của mục tiêu được kiểm tra theo điều kiện $\nu_{12}\nu_{21} < 1$ [20].

4.7 Thống kê và đăng ký trước tiêu chí

IN100 gồm 100 điều kiện kiểm tra rút với seed 123. Mức giảm MAE tương đối và KTC 95% được tính bằng bootstrap phân vị ghép cặp theo điều kiện, với 10 000 lần lấy mẫu lại [18]. Một cải thiện chỉ được khẳng định khi KTC không chứa 0. Các tiêu chí được ghi lại trước mỗi thí nghiệm, gồm: giảm MAE ít nhất 20% với mẫu đơn lẻ; MAE không tăng có ý nghĩa sau bước chọn tốt nhất trong 30 mẫu; trung vị sai số tương đối tối đa 8% tại $\nu_{12}^* = -2,0$; tương quan Spearman trung bình tối thiểu 0,7 cho điểm tổng hợp; với KAN, KTC không chứa 0 ở cả hai seed; với WIRE, tỉ lệ trúng tối thiểu 30% và R^2 FE > 0 . L-BFGS trên GPU không tắt định từng bit, và các lần chạy lặp lệch nhau khoảng 0,006 về R^2 .

Dữ liệu và mã nguồn

Mã nguồn, checkpoint đã huấn luyện và toàn bộ kết quả theo từng điều kiện dùng cho các bảng và hình sẽ được công bố tại [đường dẫn kho mã - sẽ bổ sung].

Lời cảm ơn và xung đột lợi ích

[Sẽ bổ sung.]

Tài liệu tham khảo

- [1] Roderic Lakes. Foam structures with a negative Poisson's ratio. *Science*, 235(4792):1038–1040, 1987. doi: 10.1126/science.235.4792.1038.
- [2] Kenneth E. Evans and Andrew Alderson. Auxetic materials: functional materials and structures from lateral thinking! *Advanced Materials*, 12(9):617–628, 2000. doi: 10.1002/(SICI)1521-4095(200005)12:9<617::AID-ADMA617>3.0.CO;2-3.

- [3] Katia Bertoldi, Vincenzo Vitelli, Johan Christensen, and Martin van Hecke. Flexible mechanical metamaterials. *Nature Reviews Materials*, 2:17066, 2017. doi: 10.1038/natrevmats.2017.66.
- [4] Ole Sigmund. Materials with prescribed constitutive parameters: an inverse homogenization problem. *International Journal of Solids and Structures*, 31(17):2313–2329, 1994. doi: 10.1016/0020-7683(94)90154-6.
- [5] Ulrik D. Larsen, Ole Sigmund, and Siebe Bouwstra. Design and fabrication of compliant micromechanisms and structures with negative Poisson’s ratio. *Journal of Microelectromechanical Systems*, 6(2):99–106, 1997. doi: 10.1109/84.585787.
- [6] Martin P. Bendsøe and Ole Sigmund. *Topology Optimization: Theory, Methods, and Applications*. Springer, Berlin, 2003. doi: 10.1007/978-3-662-05086-6.
- [7] Liwei Wang, Yu-Chin Chan, Faez Ahmed, Zhao Liu, Ping Zhu, and Wei Chen. Deep generative modeling for mechanistic-based learning and design of metamaterial systems. *Computer Methods in Applied Mechanics and Engineering*, 372:113377, 2020. doi: 10.1016/j.cma.2020.113377.
- [8] Yunwei Mao, Qi He, and Xuanhe Zhao. Designing complex architected materials with generative adversarial networks. *Science Advances*, 6(17):eaaz4169, 2020. doi: 10.1126/sciadv.aaz4169.
- [9] Siddhant Kumar, Stephanie Tan, Li Zheng, and Dennis M. Kochmann. Inverse-designed spinodoid metamaterials. *npj Computational Materials*, 6:73, 2020. doi: 10.1038/s41524-020-0341-6.
- [10] Jan-Hendrik Bastek, Siddhant Kumar, Bastian Telgen, Raphaël N. Glaesener, and Dennis M. Kochmann. Inverting the structure–property map of truss metamaterials by deep learning. *Proceedings of the National Academy of Sciences*, 119(1):e2111505119, 2022. doi: 10.1073/pnas.2111505119.
- [11] Hunter T. Kollmann, Diab W. Abueidda, Seid Koric, Erman Guleryuz, and Nahil A. Sobh. Deep learning for topology optimization of 2D metamaterials. *Materials & Design*, 196:109098, 2020. doi: 10.1016/j.matdes.2020.109098.
- [12] Xiaoyang Zheng, Ta-Te Chen, Xiaofeng Guo, Sadaki Samitsu, and Ikumu Watanabe. Controllable inverse design of auxetic metamaterials using deep learning. *Materials & Design*, 211:110178, 2021. doi: 10.1016/j.matdes.2021.110178.
- [13] Helda Pahlavani, Kostas Tsifoutis-Kazolis, Mauricio C. Saldivar, Prerak Mody, Jie Zhou, Mohammad J. Mirzaali, and Amir A. Zadpoor. Deep learning for size-agnostic inverse design of random-network 3D printed mechanical metamaterials. *Advanced Materials*, 36(6):2303481, 2024. doi: 10.1002/adma.202303481.
- [14] Jan-Hendrik Bastek and Dennis M. Kochmann. Inverse design of nonlinear mechanical metamaterials via video denoising diffusion models. *Nature Machine Intelligence*, 5:1466–1475, 2023. doi: 10.1038/s42256-023-00762-x.
- [15] Brandon Trabucco, Aviral Kumar, Xinyang Geng, and Sergey Levine. Conservative objective models for effective offline model-based optimization. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 10358–10368, 2021.
- [16] James K. Guest, Jean H. Prévost, and Ted Belytschko. Achieving minimum length scale in topology optimization using nodal design variables and projection functions. *International Journal for Numerical Methods in Engineering*, 61(2):238–254, 2004. doi: 10.1002/nme.1064.
- [17] Fengwen Wang, Boyan Stefanov Lazarov, and Ole Sigmund. On projection methods, convergence and robust formulations in topology optimization. *Structural and Multidisciplinary Optimization*, 43(6):767–784, 2011. doi: 10.1007/s00158-010-0602-y.

- [18] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, New York, 1993. doi: 10.1201/9780429246593.
- [19] Dong C. Liu and Jorge Nocedal. On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, 45:503–528, 1989. doi: 10.1007/BF01589116.
- [20] B. M. Lempriere. Poisson’s ratio in orthotropic materials. *AIAA Journal*, 6(11):2226–2227, 1968. doi: 10.2514/3.4974.
- [21] Ziming Liu, Yixuan Wang, Sachin Vaidya, Fabian Ruehle, James Halverson, Marin Soljačić, Thomas Y. Hou, and Max Tegmark. KAN: Kolmogorov–Arnold networks, 2024. arXiv:2404.19756.
- [22] Vishwanath Saragadam, Daniel LeJeune, Jasper Tan, Guha Balakrishnan, Ashok Veeraraghavan, and Richard G. Baraniuk. WIRE: Wavelet implicit neural representations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 18507–18516, 2023.
- [23] Martin P. Bendsøe. Optimal shape design as a material distribution problem. *Structural Optimization*, 1:193–202, 1989. doi: 10.1007/BF01650949.
- [24] Ole Sigmund. A 99 line topology optimization code written in Matlab. *Structural and Multidisciplinary Optimization*, 21(2):120–127, 2001. doi: 10.1007/s001580050176.
- [25] Erik Andreassen, Anders Clausen, Mattias Schevenels, Boyan S. Lazarov, and Ole Sigmund. Efficient topology optimization in MATLAB using 88 lines of code. *Structural and Multidisciplinary Optimization*, 43(1):1–16, 2011. doi: 10.1007/s00158-010-0594-7.
- [26] Blaise Bourdin. Filters in topology optimization. *International Journal for Numerical Methods in Engineering*, 50(9):2143–2158, 2001. doi: 10.1002/nme.116.
- [27] J. M. Guedes and N. Kikuchi. Preprocessing and postprocessing for materials based on the homogenization method with adaptive finite element methods. *Computer Methods in Applied Mechanics and Engineering*, 83(2):143–198, 1990. doi: 10.1016/0045-7825(90)90148-F.
- [28] Erik Andreassen and Casper Schousboe Andreasen. How to determine composite material properties using numerical homogenization. *Computational Materials Science*, 83:488–495, 2014. doi: 10.1016/j.commatsci.2013.09.006.
- [29] Liang Xia and Piotr Breitkopf. Design of materials using topology optimization and energy-based homogenization approach in Matlab. *Structural and Multidisciplinary Optimization*, 52(6):1229–1241, 2015. doi: 10.1007/s00158-015-1294-0.
- [30] Krister Svanberg. The method of moving asymptotes—a new method for structural optimization. *International Journal for Numerical Methods in Engineering*, 24(2):359–373, 1987. doi: 10.1002/nme.1620240207.
- [31] M. D. McKay, R. J. Beckman, and W. J. Conover. A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21(2):239–245, 1979. doi: 10.2307/1268522.
- [32] I. M. Sobol’. On the distribution of points in a cube and the approximate evaluation of integrals. *USSR Computational Mathematics and Mathematical Physics*, 7(4):86–112, 1967. doi: 10.1016/0041-5553(67)90144-9.
- [33] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

- [34] Tom Gustafsson and G. D. McBain. scikit-fem: A Python package for finite element assembly. *Journal of Open Source Software*, 5(52):2369, 2020. doi: 10.21105/joss.02369.
- [35] Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations (ICLR)*, 2014. arXiv:1312.6114.
- [36] Kihyuk Sohn, Honglak Lee, and Xinchen Yan. Learning structured output representation using deep conditional generative models. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [37] Samuel R. Bowman, Luke Vilnis, Oriol Vinyals, Andrew Dai, Rafal Jozefowicz, and Samy Bengio. Generating sentences from a continuous space. In *Proceedings of the 20th SIGNLL Conference on Computational Natural Language Learning*, pages 10–21, 2016. doi: 10.18653/v1/K16-1002.
- [38] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015. arXiv:1412.6980.